Parametrización avanzada: temperatura, output schemas y few-shot.

Explora técnicas avanzadas para ajustar parámetros de modelos de IA generativa, diseñar esquemas de salida robustos y aplicar few-shot learning en pipelines clínicos, integrando parsing con LlamaCloud y orquestación en Make/n8n para flujos auto-mejorables.

Introducción

¿Alguna vez te has preguntado cómo controlar la creatividad de un modelo de IA generativa para que produzca resultados clínicos precisos y consistentes? En entornos sensibles como healthcare, no basta con obtener respuestas; es crucial que estas sean trazables, validadas y adaptables a contextos específicos.

En esta unidad, profundizaremos en técnicas avanzadas de parametrización que te permitirán ajustar la temperatura y top-p para controlar la generación de texto, diseñar esquemas de salida (*output schemas*) que aseguren formatos estandarizados y validables, y aplicar *few-shot learning* para mejorar la precisión contextual de tus prompts. Además, exploraremos cómo integrar parsing de documentos clínicos con LlamaCloud y orquestar estos procesos en plataformas low-code como Make y n8n.

Al finalizar, estarás capacitado para configurar modelos generativos con parámetros precisos y diseñar pipelines robustos que cumplan con los estándares de producción en el sector salud, preparando el terreno para flujos auto-mejorables que veremos en unidades posteriores.

Control de Creatividad: Temperatura y Top-p

La **temperatura** es un parámetro que ajusta la aleatoriedad en la generación de texto. Valores bajos (p.ej., 0.2) producen respuestas más deterministas y conservadoras, ideales para contextos clínicos donde la precisión es clave. Valores altos (p.ej., 0.8) generan respuestas más creativas pero menos predecibles.

Ejemplo comparativo

Pregunta: **"¿Cuál es la mejor pizza?"**

Con temperatura baja (0.2)

> *"No existe una única mejor pizza. La elección depende del gusto personal, pero las opciones más populares suelen ser la pizza margarita por su equilibrio entre tomate, mozzarella y albahaca, o la pepperoni por su sabor intenso."*

Características: respuesta neutral, estructurada, predecible, evita afirmaciones absolutas y prioriza información general.

Con temperatura alta (0.8)

> *“La mejor pizza es la que sale del horno con la mozzarella burbujeando y la masa crujiente, pero si hay que elegir, una napolitana auténtica con tomate fresco, albahaca y aceite de oliva suele ser imbatible. Aunque, claro, en una noche con amigos, una pepperoni bien cargada puede ganar por goleada.”*

Características: lenguaje más expresivo, mayor variación, metáforas o matices subjetivos, menos rigidez en la formulación.

Este contraste muestra cómo la temperatura no cambia solo el contenido, sino también el **estilo, seguridad y variabilidad** de la respuesta.

El **top-p** (o *nucleus sampling*) limita la selección de palabras a un subconjunto cuya probabilidad acumulada alcanza un umbral p, equilibrando diversidad y coherencia.

> ***Ejemplo:*** *En un pipeline de generación de reportes médicos, configurar temperatura en 0.3 y top-p en 0.9 ayuda a mantener la precisión sin perder naturalidad.*

Diseño y Validación de Output Schemas

Un **output schema** es una estructura predefinida que especifica el formato esperado de la salida del modelo, facilitando la validación automática y la trazabilidad.

Por qué se necesita un output determinístico en una LLM

Cuando una LLM responde con texto libre, la salida puede variar en redacción, orden o formato incluso si el contenido es similar. Esto es útil para conversación humana, pero problemático cuando la respuesta debe ser **procesada automáticamente por un programa**.

Un sistema informático no interpreta matices lingüísticos como una persona. Si se espera extraer campos concretos (por ejemplo: diagnóstico, prioridad, fecha o categoría), un texto libre obliga a aplicar heurísticas frágiles o procesamiento adicional, lo que aumenta el riesgo de errores.

En cambio, si la LLM genera una **estructura fija y determinística**, como un objeto con campos definidos, el programa puede:

- leer directamente cada campo
- validar que existan los valores obligatorios
-

rechazar respuestas mal formadas

- almacenar los datos de forma confiable

En términos prácticos, no es lo mismo recibir:

> *“El correo parece urgente y trata sobre una reunión mañana.”*

que recibir:

```
{
  "priority": "high",
  "topic": "meeting",
  "due_date": "tomorrow"
}
```

La segunda forma puede integrarse automáticamente en un sistema de tareas; la primera requiere interpretación adicional.

Qué es JSON

JSON (JavaScript Object Notation) es un formato estándar para representar datos estructurados. Se utiliza ampliamente en APIs y sistemas modernos porque es:

- legible por humanos
- fácil de procesar por programas
- compatible con múltiples lenguajes

- liviano y flexible

JSON organiza la información en:

- **pares clave–valor**
- **objetos** (entre llaves `{}`)
- **listas** o arrays (entre corchetes `[]`)

Ejemplo simple:

```
{
  "name": "Ana",
  "age": 32,
  "active": true
}
```

En el contexto de LLMs, pedir que la salida esté en JSON permite convertir la respuesta en datos directamente utilizables por otros sistemas.

Ejemplos de JSON como output de una LLM

1. Clasificación de reseña de película

```
{
  "movie_title": "Incept
  "sentiment": "positive
  "rating": 4.5,
  "themes": ["sci-fi", "
  "summary": "A visually
}
```

---

2. Resumen estructurado de un email

```
{
  "sender": "cliente@emp
  "topic": "Solicitud de
  "priority": "medium",
  "action_required": tru
  "summary": "El cliente
}
```

---

3. Extracción de información clínica

```
{
  "patient_id": "12345",
  "symptoms": ["fiebre",
  "duration_days": 3,
  "risk_level": "moderat
  "recommended_action":
}
```

---

4. Evaluación de ticket de soporte

```
{
  "ticket_id": "T-8891",
  "category": "billing",
  "priority": "high",
  "requires_human_agent"
  "detected_language": "
}
```

Beneficios:

- Garantiza consistencia en datos clínicos generados
- Facilita integración con sistemas downstream
- Permite validación automática para cumplimiento regulatorio

Ejemplo de esquema JSON para un resumen clínico:

```
json
```

```
{
  "patient_id": "string"
  "diagnosis": "string",
  "recommendations": ["s
}
```

Implementar validaciones que rechacen salidas que no cumplan el esquema es una buena práctica para producción.

Few-Shot Learning en Prompts

El **few-shot learning** consiste en proveer ejemplos contextuales en el prompt para guiar al modelo hacia respuestas más precisas y relevantes.

> ***Ejemplo:*** *Incluir ejemplos de diagnósticos previos y sus interpretaciones para que el modelo aprenda el formato y estilo esperado.*

Esta técnica es especialmente útil en dominios clínicos donde la precisión y el contexto son críticos.

Ejemplo sin few-shot

Prompt:

> *Analiza el siguiente resultado clínico y genera una interpretación breve:*
> *"Paciente con glucosa en ayunas de 130 mg/dL".*

Posible respuesta del modelo:

> *El nivel de glucosa es elevado y podría indicar un problema metabólico. Se recomienda consultar con un profesional de salud.*

Aquí el modelo responde de forma general. No queda claro el nivel de detalle esperado, el formato ni el criterio clínico específico.

Ejemplo con few-shot (incluyendo ejemplos)

Prompt:

> *Analiza resultados clínicos y genera una interpretación en formato:*
>
> *****Nivel:** (Normal / Riesgo / Alto)*
>
> *****Interpretación:** texto breve*
>
> *****Recomendación:** acción sugerida*
>
> *Ejemplo 1:*
>
> *Resultado: "Paciente con glucosa en ayunas de 95 mg/dL"*
>
> *Nivel: Normal*
>
> *Interpretación: Valor dentro del rango esperado para ayuno.*
>
> *Recomendación: Mantener controles periódicos.*
>
> *Ejemplo 2:*
>
> *Resultado: "Paciente con glucosa en ayunas de 115 mg/dL"*
>
> *Nivel: Riesgo*
>
> *Interpretación: Valor ligeramente elevado, compatible con posible prediabetes.*
>
> *Recomendación: Control médico y evaluación de hábitos.*
>
> *Ahora analiza:*
>
> *Resultado: "Paciente con glucosa en ayunas de 130 mg/dL".*

Posible respuesta del modelo:

> *Nivel: Alto*
>
> *Interpretación: Valor elevado compatible con hiperglucemia y posible diabetes.*
>
> *Recomendación: Evaluación médica y confirmación diagnóstica con estudios adicionales.*

El segundo prompt funciona mejor porque los ejemplos:

- definen el formato esperado
- muestran el nivel de detalle
- orientan el criterio clínico

-

reducen ambigüedad

En términos prácticos, el few-shot learning convierte el prompt en una especie de **mini-guía de estilo y comportamiento**, permitiendo que el modelo imite patrones correctos sin necesidad de entrenamiento adicional.

Parsing con LlamaCloud

LlamaCloud es una herramienta que permite extraer texto y metadatos de documentos clínicos en formatos PDF, DOCX, PPTX, etc., facilitando la ingestión de datos no estructurados en pipelines automatizados.

Su integración permite:

- Automatizar la extracción de información relevante
- Preprocesar datos para modelos generativos
- Mantener trazabilidad y auditoría de fuentes

Markdown como “lenguaje natural” de las LLMs

Aunque las LLMs pueden procesar texto plano, en la práctica funcionan mejor cuando el contenido está estructurado de forma clara. Aquí entra **Markdown**, un formato de texto ligero que permite representar estructura (títulos, listas, tablas, énfasis, enlaces) sin depender de estilos visuales complejos como los de Word o PDF.

Markdown usa símbolos simples para indicar formato:

```
# Título principal
## Subtítulo
**Negrita**
- Lista
- De elementos
| Campo | Valor |
|------|------|
| Edad | 45 |
```

Esto es texto legible para humanos y, al mismo tiempo, **explícitamente estructurado para máquinas**. Para una LLM, Markdown ayuda a:

- distinguir secciones
- identificar encabezados
- reconocer tablas y relaciones
- mantener jerarquía de información
- reducir ambigüedad del texto

Por eso se suele decir, de forma práctica, que Markdown es “el idioma preferido” de las LLMs: no porque sea obligatorio, sino porque facilita que el modelo entienda el contexto y la organización del contenido.

Cómo LlamaCloud transforma documentos a Markdown

Los documentos clínicos reales rara vez vienen en formato ideal para IA:

-

PDFs con columnas

- Word con estilos visuales
- presentaciones PPT con texto disperso
- tablas embebidas
- encabezados no explícitos

Si se envía ese contenido directamente a una LLM, puede perderse:

- la estructura
- la relación entre títulos y contenido
- el orden correcto de lectura
- las tablas como entidades

LlamaCloud aborda este problema convirtiendo los documentos originales en una **representación estructurada en Markdown**. En este proceso:

1. Detecta títulos, subtítulos y secciones
2. Reconstruye tablas en formato Markdown
3.

Ordena el texto según lectura lógica

4.

Extrae metadatos relevantes

5.

Genera una versión limpia y estructurada del documento

Por ejemplo, un informe clínico en PDF con formato visual:

```
INFORME
Paciente: Juan Pérez
Edad: 52
Resultados:
Glucosa 130 mg/dL
Colesterol 210 mg/dL
```

Puede convertirse en:

```
# Informe clínico
**Paciente:** Juan Pérez
**Edad:** 52
## Resultados
| Parámetro | Valor |
|-----------|-------|
| Glucosa | 130 mg/dL |
| Colesterol | 210 mg/dL
```

Esta versión Markdown es mucho más fácil de procesar por una LLM, ya que mantiene la estructura semántica del documento sin el ruido visual del formato original.

Enlace a LlamaCloud

https://www.llamaindex.ai/llama-cloud*

En entornos clínicos y biotecnológicos, la precisión y trazabilidad de la información generada por modelos de IA son fundamentales para la toma de decisiones y cumplimiento regulatorio. Ajustar parámetros como temperatura y top-p permite controlar la creatividad del modelo, evitando resultados erráticos o poco confiables.

El diseño de output schemas asegura que la información generada cumpla con formatos estandarizados, facilitando su integración en sistemas electrónicos de salud y auditorías.

El uso de few-shot learning en prompts mejora la contextualización y precisión, especialmente en dominios especializados donde los datos de entrenamiento pueden ser limitados.

Herramientas como LlamaCloud permiten automatizar la extracción de datos de documentos clínicos, integrándose con plataformas low-code para construir pipelines robustos y escalables.

Este enfoque integral prepara a los profesionales para diseñar sistemas de automatización avanzados, observables y mantenibles, alineados con las exigencias del sector salud y biotecnología.

Para practicar

Instrucciones:

Práctica: Configuración y Validación de un Pipeline Clínico Parametrizado

En esta actividad, aplicarás los conceptos aprendidos para diseñar un pipeline que:

1. Ajuste parámetros de temperatura y top-p para un modelo generativo orientado a resúmenes clínicos.
2. Defina y valide un output schema JSON para la salida del modelo.
3. Integre parsing de documentos PDF clínicos usando LlamaCloud.

4. Orqueste el flujo en Make o n8n, incluyendo manejo básico de webhooks.

Pasos:

1. **Configura el modelo generativo:** Define temperatura en 0.3 y top-p en 0.9.
2. **Diseña un output schema:** Crea un esquema JSON que incluya campos para patient_id, diagnosis y recommendations.
3. **Implementa validación:** Simula la validación de la salida del modelo contra el esquema.
4. **Configura parsing con LlamaCloud:** Prepara un flujo que extraiga texto de un PDF clínico.
5. **Orquesta en Make/n8n:** Crea un flujo que conecte la extracción, generación y validación, usando webhooks para notificaciones.

Reflexión:

- ¿Cómo afecta la parametrización a la calidad y consistencia de la salida?
- ¿Qué ventajas aporta el uso de output schemas en producción?
- ¿Cómo facilita la integración con sistemas existentes el uso de plataformas low-code?

Al completar esta práctica, estarás listo para implementar pipelines clínicos robustos y parametrizados, base para flujos auto-mejorables.

Entregable:

Documento Google Docs de 4-5 páginas que incluya:

- Descripción del pipeline diseñado.
- Parámetros configurados y justificación.
- Output schema JSON con explicación.
- Diagrama del flujo en Make o n8n.
- Reflexión sobre los beneficios y desafíos encontrados.

El documento debe ser profesional, claro y orientado a la aplicación en entornos clínicos.